ÉVALUATION PILOTE | 3 NOVEMBRE 2026

LangExtract
Valeur métier et limites

Pré-extraire des informations vérifiables, sans confondre traçabilité et exhaustivité.

10 PDF synthétiques · 12 pages · 41 références · 30 appels réels. Factures, contrats, courrier, tableau, anglais, corrections, document long, accents et contrôles négatifs.

Mesure	1 passe (A+B)	2 passes
Précision exacte	95.9 %	100.0 %
Rappel exact	85.4 %	90.2 %
F1 micro	90.3 %	94.9 %
Temps médian	1.97 s	3.66 s
Temps moyen	2.36 s	3.21 s
TP / FP / FN	70 / 3 / 12	37 / 0 / 4
Documents exploitables	18 / 18	9 / 9

Décision proposée

Poursuivre un pilote de préremplissage avec validation humaine. Les offsets et exports rendent la preuve consultable ; les omissions et la variabilité empêchent de conclure à une extraction autonome fiable.

110/110 extraits sont présents dans la source et correctement localisés après normalisation des espaces/Unicode. Trois noms restent incomplets au regard du contrat malgré cette localisation valide.

Limite décisive : aucune comparaison à un simple prompt du même modèle. Ni gain de temps humain ni coût fournisseur ne sont mesurés. Cette étude démontre un comportement du service, pas la supériorité du framework.

Où la valeur se confirme et où elle se dégrade

Document	1 passe A	1 passe B	2 passes
Facture simple	100.0 %	88.9 %	100.0 %
Contrat et parties	100.0 %	100.0 %	100.0 %
Courrier administratif	80.0 %	100.0 %	100.0 %
Tableau de commandes	100.0 %	100.0 %	92.3 %
Document en anglais	88.9 %	66.7 %	100.0 %
Valeurs annulées et applicables	80.0 %	80.0 %	80.0 %
Document long avec entités dispersées	85.7 %	85.7 %	85.7 %
Accents et répétitions	88.9 %	66.7 %	88.9 %
Contrôle négatif sans entité	0 faux positif	0 faux positif	0 faux positif
Contrôle négatif sans couche texte	422 attendu	422 attendu	422 attendu

Lecture des écarts

Stabilité : 5/9 documents textuels identiques entre A et B (4/8 positifs). La mesure compare classe, extrait et multiplicité, sans les attributs ni positions.

Omissions d’organisations, noms tronqués et occurrence répétée manquante constituent les principaux écarts. Le tableau est complet dans les deux essais à une passe, puis perd une organisation dans l’essai à deux passes.

Deux passes : +4.5 points de F1 groupé, mais un temps médian multiplié par 1.86. Une seule exécution à deux passes ne permet pas de généraliser cet avantage.

Contrôles négatifs : 3/3 listes vides correctes pour le texte neutre ; 3/3 rejets OCR attendus pour le PDF image. Les 27 appels textuels réussissent sans erreur HTTP inattendue.

Méthode, portée et décision suivante

Mesure contrôlée

Références écrites avant les appels et vérifiées contre le texte des PDF. Prompt métier fixe, un worker, segments de 1 200 caractères. Trois profils : une passe A, une passe B et deux passes. Ordre entrelacé avec graine 20261103. Aucune retouche du prompt après observation.

Qualité stricte

TP = même classe et extrait complet. Comparaison de multiensembles, espaces et Unicode NFC normalisés uniquement. Un nom tronqué compte FP + FN. F1 = 2TP / (2TP + FP + FN). Attributs non notés. Scans exclus des scores textuels. Les négatifs n’ajoutent pas de vrais positifs.

Traçabilité et performance

Offsets contrôlés contre document.text ; pas d’association référence-position pour les occurrences répétées. Durées HTTP complètes incluant PDF, inférence et exports. Premier appel de 10,174 s conservé. Pas de benchmark GPU ni de test de charge.

Limites à annoncer

Corpus synthétique restreint, 41 occurrences, pas d’annotation indépendante. Noms artificiels susceptibles d’accentuer des ambiguïtés. Modèle exact, paramètres, tokens et coûts non exposés par cette API. Pas de comparaison directe LLM, de mesure du temps de correction ou de généralisation statistique.

Prochain jalon professionnel

Comparer au même modèle via accès direct, sur un corpus métier autorisé annoté indépendamment. Geler le contrat et le jeu de test. Mesurer par champ : exactitude, omissions, attributs, preuve, coût et minutes de correction. Définir les seuils avec les métiers avant la décision de production.

Pièces auditables

PDF du corpus, références, réponses synthétiques complètes, mesures, scripts de scoring et tests versionnés. README.md détaille le protocole et la reproduction. Token utilisé uniquement en mémoire ; aucun secret dans le dossier.