ÉTUDE CONTRÔLÉE | 3 NOVEMBRE 2026

Extraction en français Prompt direct ou LangExtract ?

40 documents français - 158 références - 240 traitements

Corpus synthétique de 44 pages : 36 documents positifs, 4 négatifs. Deux exécutions par méthode ; même endpoint ai-flash, modèle amont annoncé qwen3.6.

Mesure	Prompt direct	LangExtract 1 passe	LangExtract 2 passes
Précision	98.7 %	98.7 %	98.1 %
Rappel	96.8 %	96.8 %	97.5 %
F1 micro	97.8 %	97.8 %	97.8 %
Succès / traitements	80/80	80/80	80/80
TP / FP / FN	306/4/10	306/4/10	308/6/8

Ce que les mesures permettent de décider

Écart F1 LangExtract une passe / prompt direct : +0.00 points. Aucune différence globale de F1 n’est observée entre ces deux méthodes.

F1 à deux passes : écart de +0.014 point face au direct, pour 2.27 fois les tokens. Répétabilité observée (direct / une passe / deux passes) : 34/40, 38/40 et 40/40. Ces écarts descriptifs ne sont pas une preuve statistique de supériorité.

Comparer une brique de framework à une requête complète

Le prompt direct lit le document entier. LangExtract est mesuré à 1 puis 2 passes, avec segments de 1 200 caractères. La baseline reçoit les mêmes exemples et un alignement textuel simple : la présence d’offsets ne lui est pas refusée artificiellement.

Portée : 40 cas rédigés pour cette étude, sans validation indépendante. Les résultats décrivent cette configuration et ne prouvent pas une supériorité universelle. Ni temps humain ni coût en euros ne sont mesurés.

Le français : qualité par champ et cas difficiles

Classe - P / R	Prompt direct	LangExtract 1 passe	LangExtract 2 passes
Montant (amount)	100.0 % / 97.8 %	100.0 % / 97.8 %	100.0 % / 100.0 %
Date (date)	100.0 % / 100.0 %	100.0 % / 100.0 %	100.0 % / 100.0 %
E-mail (email)	100.0 % / 100.0 %	100.0 % / 100.0 %	100.0 % / 100.0 %
Facture (invoice)	100.0 % / 100.0 %	100.0 % / 100.0 %	100.0 % / 100.0 %
Organisation (org)	95.4 % / 94.3 %	95.5 % / 96.6 %	93.5 % / 97.7 %
Personne (person)	100.0 % / 94.1 %	100.0 % / 94.1 %	100.0 % / 88.2 %
Référence (ref)	100.0 % / 96.9 %	100.0 % / 93.8 %	100.0 % / 96.9 %

Focus sur les quatre documents longs

Documents longs	Prompt direct	LangExtract 1 passe	LangExtract 2 passes
F1 micro	98.7 %	100.0 %	100.0 %
Temps médian	1.72 s	2.16 s	5.15 s

Interprétation métier

Le bon critère est la couverture des informations applicables, pas seulement une réponse JSON valide. Le corpus inclut des montants annulés, des dates remplacées, des tableaux, des noms accentués, des répétitions et des informations éloignées dans le texte.

Les textes longs restent petits par rapport au contexte annoncé de 262 144 tokens. Le prompt direct peut donc lire ces textes d’un seul tenant. La segmentation testée n’est pas un réglage optimisé pour ce modèle.

La synthèse détaillée README.md donne les 40 scores par document. Les références, réponses et prompts sont archivés pour vérifier chaque faux positif ou omission.

Ressources, preuves et répétabilité

Mesure	Prompt direct	LangExtract 1 passe	LangExtract 2 passes
Temps médian	1.28 s	1.28 s	2.53 s
Temps moyen	1.55 s	1.53 s	3.10 s
Appels HTTP LLM	80	96	192
Tokens entrée	45 998	53 318	106 636
Tokens sortie	9 402	9 614	19 329
Tokens totaux	55 400	62 932	125 965
Multiplicateur tokens	1.00 x	1.14 x	2.27 x

Contrôles de sortie

Contrôle	Prompt direct	LangExtract 1 passe	LangExtract 2 passes
Entités identiques A/B	34/40	38/40	40/40
Négatifs sans entité	8/8	8/8	8/8
Offsets valides	310/310	310/310	314/314
Extraits dans la source	310/310	310/310	314/314

Comment lire ces chiffres

Les tokens proviennent du champ usage renvoyé par le serveur ; leur volume n’est pas une facture. Le budget total n’est pas égalisé : LangExtract peut demander plusieurs appels. La durée couvre le texte vers les entités annotées, pas l’upload PDF ni les exports de l’application.

Les offsets de la baseline sont construits par recherche textuelle tolérant les espaces ; ceux de LangExtract viennent de son resolver. Le contrôle local des offsets ne garantit pas l’identité de l’occurrence attendue lorsque des textes se répètent. La stabilité ignore attributs et positions.

Méthode auditable et conditions de généralisation

Comparaison appariée

Mêmes 40 PDF et couche texte pour les trois méthodes. Même prompt métier français, même exemple, même alias et endpoint. Température 0, seed 42, JSON mode et plafond de 4 096 tokens par appel vérifiés systématiquement. Un worker, ordre entrelacé fixé ; pas de retries ni de tuning après observation.

Scoring strict

Classe et extrait complet doivent correspondre. Comparaison de multiensembles ; espaces et NFC normalisés uniquement. Un nom tronqué compte FP + FN. Précision = TP/(TP+FP), rappel = TP/(TP+FN), F1 = 2TP/(2TP+FP+FN). Les cas échoués ne sont pas retirés du bilan.

Modèle observé

ai-flash annonce qwen3.6, raisonnement désactivé. Alias avant/après inchangé : True. LangExtract 1.7.1 est exécuté localement et instrumenté. Checkpoint, quantification, matériel, cache et tarif exacts ne sont pas exposés.

Limites du corpus

Français intégral mais synthétique : situations choisies, noms fictifs, références rédigées par l’auteur sans double annotation. Pas d’échantillonnage représentatif ni de test statistique de population. Attributs, relations, OCR et temps de correction humaine non mesurés.

Suite de décision

Valider sur documents métier autorisés annotés indépendamment. Séparer réglage et test, choisir les métriques par risque et chronométrer les corrections. Tester le réglage de segmentation sur le jeu de réglage, puis geler le protocole avant la validation finale.

Dossier livré

Synthèse PDF, protocole, corpus et références, PDF originaux, 240 réponses instrumentées, snapshots modèles, mesures de tokens et scripts de reproduction. L’ancien pilote reste archivé ; ses scores ne sont pas directement comparables à cette nouvelle campagne.